

UNIVERSITATEA „1 DECEMBRIE 1918” DIN ALBA IULIA

ANALIZA PREDICTIVĂ A CHIRIILOR PRIN DEEP LEARNING

Ion Gondrea — Proiect Practic Final

Disciplina: Calcul Neuronal

CAPITOLUL I

CADRUL TEORETIC ȘI DATELE

DEFINIREA PROBLEMEI ȘI OBIECTIVELOR

OBIECTIV ȘTIINȚIFIC

Modelarea unei funcții matematice de aproximare pentru prețul chiriilor rezidențiale, utilizând arhitecturi de rețele neuronale profunde.

METODOLOGIE

Analiza comparativă a capacității de generalizare între arhitecturi complexe (Deep) și modele de control (Shallow Baseline).

DATASET ȘI PROTOCOLUL DE EVALUARE

PARAMETRU DATASET	DESCRIERE ȘI VALOARE
Sursă Date	House_Rent_Dataset.csv (Public / Kaggle)
Variabile Independente	BHK, Size, Bathrooms, City, Furnishing Status, Tenant Preferred
Protocol Split (Obligatoriu)	80% Antrenare (din care 20% Validare) 20% Testare Independentă
Dimensiune Target	Regresie continuă (Preț exprimat în INR)

PIPELINE-UL DE PREPROCESARE

STANDARDIZARE

Aplicarea **StandardScaler** pe attributele numerice (Size, BHK) pentru scalare unitară.

CODIFICARE

Utilizarea **OneHotEncoder** pentru transformarea variabilelor categoricale în vectori binari.

OPTIMIZARE

Eliminarea coloanelor redundante (Posted On, Floor) pentru minimizarea zgomotului informațional.

CAPITOLUL II


ARHITECTURĂ ȘI REZULTATE

ARHITECTURA REȚELEI PROFUNDE (MODEL 1)

- ■ **Topologie Secvențială:** 3 straturi ascunse dotate cu 64, 32 și 16 neuroni.
 - ■ **Funcții de Activare:** ReLU pentru straturile dense; Linear pentru stratul de ieșire (Regresie).
 - ■ **Regularizare:** Dropout (0.2) implementat pentru prevenirea fenomenului de *overfitting*.
 - ■ **Monitorizare:** Early Stopping bazat pe *val_loss* cu o latență de 10 epoci.
-

REZULTATE FINALE VS. BASELINE

MODEL 1 (SOLUȚIA DEEP)



MODEL 2 (BASELINE SIMPLU)



Rezultatul indică o reducere a erorii de predicție cu peste 60% prin utilizarea arhitecturii profunde.

PUTEREA DE EXPLICAȚIE: SCORUL R^2



67.5%

SCOR R^2 REALIZAT

Indică proporția de varianță a prețurilor explicată de model. Diferența de 32.5% provine din variabile externe datasetului.

DEMONSTRAREA SOLUȚIEI FUNCȚIONALE

60,946

INR / LUNĂ (PREDICȚIE)

CAZ DE TEST: MUMBAI

Input: 3 BHK, 400 Sq.Ft, 4 Băi, Complet Mobilat.

Interpretare: Modelul confirmă valoarea ridicată a spațiilor optimizate în zonele ultra-centrale, demonstrând asimilarea regulilor pieței.

| CONCLUZII ȘI DIRECȚII VIITOARE

- ■ **Validare:** Arhitecturile Deep Learning sunt obligatorii pentru task-uri imobiliare neliniare.
 - ■ **Limitări:** Lipsa datelor GPS limitează precizia dincolo de pragul explicativ de 70%.
 - ■ **Viitor:** Integrarea hărților termice (heatmaps) și a optimizării automate a hiperparametrilor.
 - ■ **Documentație:** Repository-ul conține README.md și codul Python organizat și rulabil.
-