



Estimarea Chiriilor Imobiliare prin Calcul Neuronat

Dezvoltarea unui model de regresie Deep Learning

Student: Gondrea Ion

Disciplina: Calcul Neuronat

Definirea Problemei & Dataset

Obiectivul Proiectului

Automatizarea și eficientizarea procesului de stabilire a chiriilor. Trecerea de la evaluări subiective umane la o predicție bazată pe corelații matematice învățate dintr-un istoric de tranzacții.

Dataset Utilizat

House_Rent_Dataset.csv (4700+ înregistrări din diverse orașe).

- **Target (Y):** Prețul chiriei (Rent)
- **Features (X):**

Variabilă	Tip	Semnificație
BHK	Numeric	Număr de camere
Size	Numeric	Suprafața (mp)
City	Categoric	Orașul locației
Furnishing	Categoric	Nivelul de mobilare

Plan de Lucru & Arhitectură

Planificarea Execuției

- **Săpt. 1-4:** Explorarea datelor, Data Cleaning, definirea problemei.
- **Săpt. 5-8:** Implementarea preprocesării și scrierea modelului.
- **Săpt. 9-11:** Antrenarea modelului, tuning de hiperparametri.
- **Săpt. 12-14:** Evaluarea finală, generarea metricilor și documentarea.



Structura Repository (GitHub)

`/data` - House_Rent_Dataset.csv

`/src` - proiect_calcul_neuronal.py

`README.md` - Instrucțiuni de rulare și documentație tehnică detaliată.

Pipeline-ul de Preprocesare



1. Curățarea Datelor

S-au eliminat variabilele zgomotoase cu relevanță redusă pentru un model generalizat (ex: Data Postării, Etajul, Locația micro).



2. Standardizare

Variabilele numerice (Suprafață, Băi) au fost scalate cu `StandardScaler` (medie 0, deviație 1) pentru convergență rapidă.



3. Codificare

Variabilele textuale au fost procesate prin `OneHotEncoder`, creând o reprezentare binară inteligibilă pentru rețea.

Experiment & Soluționare Erori

Detaliile Antrenamentului

- **Arhitectură:** Multi-Layer Perceptron (64 → 32 → 16 neuroni).
- **Optimizator:** Adam, loss func. MSE.
- **Rulare:** 100 Epoci cu `EarlyStopping` (oprire la a 10-a epocă fără îmbunătățire).



Probleme Întâmpinate

Eroare la conversia datelor: Codificarea categoriilor a generat o matrice rară (Sparse Matrix), cauzând un `ValueError` la intrarea în rețea.

Soluție implementată: Ajustarea codului prin parametrul `sparse_output=False` în transformatorul `OneHotEncoder`.

Rezultate & Baseline Comparativ

Eroarea Medie Absolută (MAE) a Modelului

12,726

INR / Lună

Comparație cu Baseline

Dacă am folosi o metodă "naivă" (ex: ghicirea prețului ca fiind pur și simplu **media tuturor chirilor** din setul de date), eroarea MAE ar fi fost masivă (peste 35,000 INR).

Performanța de 12.726 INR a modelului nostru demonstrează că **rețeaua a învățat tiparele reale** și aduce o îmbunătățire cu peste 60% față de baseline.

Justificări & Direcții Viitoare

Decizii Tehnice

- **ReLU Activation:** Previne dispariția gradientului în straturile adânci.
- **Dropout (20%):** Stingerea aleatorie a nodurilor previne memorarea (overfitting) și forțează generalizarea tiparelor imobiliare.

Limitări și Viitor

- Limitare curentă: Lipsa granularității geografice. Orașul este o variabilă prea mare.
- **Dezvoltare viitoare:** Integrarea API-urilor pentru coordonate GPS (lat/long) la nivel de stradă și transformarea modelului într-o aplicație web.



Urmează demonstrația funcțională live: **Rularea codului (Partea a 6-a)**